
Υβριδικό Σύστημα Συστάσεων στο Amazon Reviews 2023

Video Games case study

Φαίδων Γραμματικόπουλος | mtn2505

MSc in Artificial Intelligence

University of Piraeus & NCSR "Demokritos"

github.com/Fgram-devAI/amazon-hybrid-recsys

- Στόχος: για χρήστη με γνωστό ιστορικό, προτείνουμε **νέα** (μη ιδωμένα) αντικείμενα Amazon.
- Content-based filtering: ομοιότητα περιεχομένου — αδύναμο όταν τα metadata είναι φτωχά.
- Collaborative filtering: μοτίβα συμπεριφοράς χρηστών — ευάλωτο σε αραιότητα / cold-start.
- Υβριδική προσέγγιση: κάθε οικογένεια καλύπτει την αδυναμία της άλλης.
- Δύο όψεις του προβλήματος: rating prediction (RMSE/MAE) και top-K recommendation (P/R/F1).


Επιλογή δεδομένων: Amazon Reviews 2023

- Video_Games — κύριο benchmark: επιβιώνει το αυστηρό 5-core, πυκνό αλλά διαχειρίσιμο τοπικά.
- Movies_and_TV — scale case: $\sim 7,4\text{M}$ αλληλεπιδράσεις· ελέγχει ότι το pipeline κλιμακώνεται.
- Digital_Music — sparsity / cold-start case: το 5-core πρακτικά το αδειάζει.

Dataset	Interactions	Users / Items
Video_Games	814.586	94.762 / 25.612
Movies_and_TV	7.441.129	657.203 / 197.943
Digital_Music	μικρός πυρήνας	--- (cold-start)

Ροή προεπεξεργασίας (Pipeline / Funnel)


- Αποδιπλοποίηση ζευγών (user, item) — κρατάμε το πιο πρόσφατο.
- 5-core filtering ($k=2$ για Digital_Music).
- Per-user χρονολογικό 80/20 split (seed 42).
- Χειρισμός missing metadata, ευθυγράμμιση στο parent_asin.
- **Κανόνας διαρροής:** features & ακμές γράφου μόνο από το train.



4,62M → dedup 4,56M → 5-core 814.586

Χαρακτηριστικά του dataset

- Μετά το 5-core: **94.762** χρήστες, **25.612** items, **814.586** αλληλεπιδράσεις.
- Sparsity $\approx$ **0.9997** (πολύ αραιό ακόμη και μετά το core).
- Κλίση προς θετικά: **80,4%** των ratings ≥ 4 (κορυφή στα 5 αστέρια).
- Χωρίς resampling: κρατάμε τη φυσική κατανομή του implicit feedback.
- Γι' αυτό το χαμηλό raw P@10 ερμηνεύεται πάντα έναντι popularity / oracle.




- Rating prediction: RMSE, MAE στο held-out test split.
- Ranking: Precision@10, Recall@10, F1@10 (σχετικό = rating ≥ 4).
- Audit μετρικές: HitRate@10, NDCG@10.
- Sampled-candidate: ανά χρήστη, held-out positives + N=100 τυχαία negatives (seed 42, ίδια για όλα τα μοντέλα).
- Oracle ceiling: διάμεσος ≈ 1 σχετικό item/χρήστη $\Rightarrow P^*_{@10} = 0,1552$, $F1^*_{@10} = 0,2551$.

Sampled, όχι full-catalog: τα νούμερα δεν συγκρίνονται άμεσα με άλλες εργασίες.

Κλασικά Collaborative Filtering baselines

- Item-KNN (KNNWithMeans, item-based): ομοιότητα items από κοινές αξιολογήσεις.
- SVD / matrix factorization: λανθάνοντα διανύσματα χρηστών & items + bias όροι.
- Σήμα μόνο από τον πίνακα ratings — όχι κείμενο/metadata.
- **SVD**: ισχυρότερο σε RMSE (1,1337) αλλά αδύναμο top-K (F1@10 0,0543).

Διαφορετικό objective $\Rightarrow$ διαφορετικός νικητής.



RMSE & MAE — βασικά & εμπλουτισμένα μοντέλα

Content-based filtering


- Προφίλ item από title + description + categories + αριθμητικά metadata (price, avg_rating, rating_number).
- Transformer embeddings: granite-embedding-97m-multilingual-r2, ℓ_2 -normalized.
- Πρόβλεψη: σταθμισμένος μέσος αξιολογήσεων ιστορικού με βάρη cosine similarity.
- Χωρίς κλασική NLP προεπεξεργασία (stemming/lemmatization): τα embeddings αξιοποιούν σειρά & συμφραζόμενα.
- Plain content: F1@10 0,0675 — κάτω από το popularity (0,1284): η σημασιολογία βοηθά αλλά δεν αρκεί.

Υβριδικά & εμπλουτισμένα content μοντέλα



- Weighted hybrid: $\hat{r} = \alpha \cdot CF + (1 - \alpha) \cdot \text{content}$ — με RMSE-tuned $\alpha \approx 1$ καταρρέει στο SVD.
- Calibrated hybrid: z-score recentering πριν τη μίξη· εξισορροπεί RMSE (1,1737), MAE (0,7679) & F1@10 (0,1003).
- content_enriched: φιλτραρισμένες κατηγορίες, αριθμητικά metadata, train-only sentiment (DistilBERT-SST2) & user-generosity offset.
- Sentiment: F1@10 0,1047 → 0,1250, αλλά MAE 0,7917 → 0,8258 — **προαιρετικό** ranking feature.

Graph recommenders

- Train-only διμερικός γράφος user--item (test ακμές ποτέ σε message passing).
- LightGCN: καθαρά collaborative ranker, BPR — **ισχυρότερος** (F1@10 0,1492, $\approx 58,5\%$ του oracle).
- GraphSAGE-MSE: graph + node features, rating regressor (RMSE 1,1613).
- GraphSAGE-BPR: ranking-oriented· βελτιώνει το ranking αλλά υστερεί του LightGCN.




- Item--item co-rating projection: ακμή όταν δύο items αξιολογούνται θετικά από κοινούς χρήστες.
- Κοινότητες με Louvain, Leiden, Spectral, Girvan--Newman· ευθυγράμμιση με κατηγορίες (purity, NMI).
- **Ερμηνευσιμότητα**, όχι training signal του recommender.



Κύρια αποτελέσματα (video_games)

- SVD κερδίζει το classic RMSE (1,1337).
- Popularity: ισχυρό sampled-ranking baseline (F1@10 0,1284).
- content_enriched πλησιάζει το popularity (F1@10 0,1250).
- LightGCN: ισχυρότερος ranker (F1@10 0,1492).
- GraphSAGE-MSE: καλύτερη rating regression· BPR βελτιώνει ranking αλλά < LightGCN.



- Διαδραστικό dashboard πάνω από τοπικά ή demo artifacts.
- Καρτέλες: Overview, Model Comparison, Graph Models + Ablations, Graph EDA, Item Explorer, Recommendations.
- Δεν υπολογίζει ξανά embeddings ή graph checkpoints· για διαδραστική χρήση μπορεί να κάνει ελαφρύ τοπικό fit σε SVD/KNN.
- Recommendations: popularity, SVD, KNN (cosine/pearson/msd), content enriched, calibrated hybrid, LightGCN και LLM hybrid (profile/query).
- **Ποιοτική επιθεώρηση** — δεν αντικαθιστά τις μετρικές RMSE/MAE/P/R/F1.

- Milvus Lite: vector search πάνω στα item embeddings (semantic neighbors).
- Neo4j: train-only γράφος user--item--category ως τεκμήρια εξήγησης.
- LLM layer (Groq, OpenAI-compatible): φυσικογλωσσική εξήγηση πάνω σε structured evidence.
- **Σημαντικό:** το LLM εξηγεί ντετερμινιστικές συστάσεις — δεν αναδιατάσσει top-K, δεν αντικαθιστά τις αξιολογούμενες μετρικές.

Προαιρετικό επίπεδο· συμβατό με τον κανόνα διαρροής (test ratings δεν εισάγονται).

- Κανένα μοντέλο δεν κερδίζει σε όλα — ο στόχος καθορίζει τον νικητή.
- Rating prediction: SVD | Top-K ranking: LightGCN.
- Το collaborative graph signal είναι το ισχυρότερο για ranking.
- Content & review-feedback βοηθούν, αλλά δεν αντικαθιστούν το collaborative σήμα.
- Μελλοντικά: full-catalog evaluation, sequence-aware (SASRec/BERT4Rec), ισχυρότερα GNN, καλύτερες LLM εξηγήσεις.

github.com/Fgram-devAI/amazon-hybrid-recsys