



ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΕΙΡΑΙΩΣ
UNIVERSITY OF PIRAEUS

Υβριδικό Σύστημα Συστάσεων στο Σύνολο Δεδομένων Amazon-Reviews-2023

Φαίδων Γραμματικόπουλος

mtn2505

Μάθημα: Εφαρμογές Τεχνητής Νοημοσύνης
Διδάσκουσα: Μ. Χαλκίδη

MSc in Artificial Intelligence
University of Piraeus & NCSR "DEMOKRITOS", Greece

Ιούνιος 2026

Εισαγωγή

Τα συστήματα συστάσεων αντιμετωπίζουν ένα διπλό πρόβλημα: πρέπει να αξιοποιούν το περιεχόμενο των αντικειμένων και ταυτόχρονα να μοντελοποιούν τη συμπεριφορά των χρηστών απέναντι σε αυτά. Οι δύο βασικές οικογένειες, content-based filtering και collaborative filtering, είναι συμπληρωματικές: η πρώτη δυσκολεύεται όταν το διαθέσιμο περιεχόμενο είναι φτωχό ή μη πληροφοριακό, ενώ η δεύτερη επηρεάζεται έντονα από αραιότητα και cold-start σενάρια. Η παρούσα εργασία οικοδομεί ένα υβριδικό σύστημα συστάσεων πάνω στο Amazon Reviews 2023 (McAuley Lab), με κύριο benchmark την κατηγορία `Video_Games`, ώστε να εξετάσει εμπειρικά πώς συνδυάζονται οι δύο προσεγγίσεις όταν όλα τα μοντέλα αξιολογούνται με κοινό πρωτόκολλο.

Το έργο υλοποιεί και συγκρίνει, υπό το ίδιο sampled-candidate πρωτόκολλο, τις παρακάτω οικογένειες μοντέλων. Όλα τα μοντέλα μοιράζονται ενιαία διεπαφή `fit / predict / recommend`, ώστε ο evaluation harness και το app να τα χειρίζονται με τον ίδιο τρόπο.

- **Content-based filtering** με transformer item embeddings (Granite-Embedding-97M-Multilingual-R2) στο `blob title + description + categories` και τυποποιημένα αριθμητικά metadata (`price`, `average_rating`, `rating_number`).
- **Item-KNN** και **SVD** ως κλασικά collaborative filtering baselines πάνω στον πίνακα `user_id × parent_asin`.
- Ένας απλός **weighted hybrid** ($\alpha \cdot \text{CF} + (1 - \alpha) \cdot \text{content}$) και ένας **calibrated hybrid** με z-score recentering ανά συνιστώσα.
- Εμπλουτισμένα content/review-feedback μοντέλα με φιλτραρισμένες κατηγορίες, train-only item-sentiment aggregates με DistilBERT και train-only user-generosity offsets.
- Γραφικοί recommenders **LightGCN**, **GraphSAGE** (MSE) και **GraphSAGE-BPR** πάνω στον train-only διμερικό γράφο user-item.
- Read-only ανάλυση γράφου και κοινοτήτων (Louvain, Leiden, Spectral, Girvan-Newman) στο item-item co-rating projection, ως εργαλείο ερμηνευσιμότητας και όχι ως feature του recommender.
- Ένα **Streamlit** app για ποιοτική επιθεώρηση EDA, μετρικών και ανά-χρήστη συστάσεων.

Η ροή **Milvus** (vector store για semantic retrieval), **Neo4j** (train-only γράφος εξήγησης) και **LLM** (Groq, OpenAI-compatible) αποτελεί προαιρετική υποδομή ανάκτησης

και επεξήγησης. Δεν αντικαθιστά το πρωτεύον αξιολογούμενο recommender layer: το LLM δεν αναδιατάσσει τα top- K , αλλά εξηγεί ντετερμινιστικές βαθμολογήσεις.

Στο κύριο benchmark `video_games`, το **SVD** παραμένει το ισχυρότερο μοντέλο σε *RMSE* μεταξύ των classic baselines, ενώ το **popularity** αναδεικνύεται ως ισχυρό sampled-ranking baseline. Το `content_enriched` βελτιώνει σαφώς το plain content και προσεγγίζει το popularity σε *F1@10*. Στους γραφικούς recommenders, το **LightGCN** κερδίζει το sampled top- K ranking, φτάνοντας περίπου το 58.5% του oracle *F1@10*. Το **GraphSAGE** με MSE είναι ισχυρότερο στο rating regression, αλλά υστερεί στο ranking, ενώ το **GraphSAGE-BPR** βελτιώνει το ranking του GraphSAGE χωρίς να ξεπερνά το LightGCN. Το sentiment βοηθάει το `content_enriched` ranking, αλλά είναι θορυβώδες στο GraphSAGE-BPR, οπότε αντιμετωπίζεται ως προαιρετικό ranking-oriented feature.

Η §1 ορίζει το πρόβλημα και αιτιολογεί την επιλογή dataset· η §2 παρουσιάζει τις μεθόδους με βάση την πραγματική υλοποίηση· η §3 παρουσιάζει την προεπεξεργασία, τις μετρικές και τα αποτελέσματα· οι §§3.12.1--3.12.5 συμπληρώνουν την παρουσίαση με την προαιρετική επεξηγηματική υποδομή και τις εντολές αναπαραγωγής· η §4 συνοψίζει συμπεράσματα και περιορισμούς. Όλος ο κώδικας, οι προδιαγραφές και οι εντολές αναπαραγωγής είναι διαθέσιμα στο ανοιχτό αποθετήριο:

<https://github.com/Fgram-devAI/amazon-hybrid-recsys>

Κεφάλαιο 1

Ορισμός Προβλήματος και Επιλογή Δεδομένων

1.1 Διατύπωση προβλήματος

Το πρόβλημα της εργασίας είναι η ανάπτυξη ενός συστήματος συστάσεων που, για έναν χρήστη με γνωστό ιστορικό αξιολογήσεων, προτείνει νέα αντικείμενα τα οποία δεν έχει ήδη αξιολογήσει. Στο συγκεκριμένο project το πρόβλημα μελετάται πάνω στο Amazon Reviews 2023, όπου κάθε αλληλεπίδραση αντιστοιχεί σε μία αξιολόγηση χρήστη για ένα προϊόν. Επομένως, το σύστημα πρέπει να αξιοποιεί ταυτόχρονα δύο πηγές πληροφορίας: το ιστορικό συμπεριφοράς των χρηστών και το περιεχόμενο/metadata των προϊόντων.

Τυπικά, έστω ένα σύνολο χρηστών U και ένα σύνολο αντικειμένων I . Κάθε item ταυτοποιείται με το πεδίο `parent_asin`, το οποίο χρησιμοποιείται ως σταθερό κλειδί συνένωσης ανάμεσα στα reviews και στα metadata. Παρατηρούμε ένα σύνολο αλληλεπιδράσεων $D \subseteq U \times I$, όπου κάθε εγγραφή περιέχει βαθμολογία $r_{u,i} \in \{1, \dots, 5\}$ και timestamp. Επιπλέον, για κάθε item υπάρχουν metadata όπως `title`, `description`, `categories`, `price`, `average_rating` και `rating_number`. Το review text θεωρείται interaction-level feedback: χρησιμοποιείται μόνο για train-only aggregates και όχι ως μόνιμο item metadata.

Η εργασία αξιολογεί δύο συμπληρωματικές εκδοχές του προβλήματος:

1. **Rating prediction:** για ένα ζεύγος (u, i) , το μοντέλο προβλέπει βαθμολογία $\hat{r}(u, i) \in [1, 5]$. Η ποιότητα μετριέται με RMSE και MAE.
2. **Top- K recommendation:** για κάθε χρήστη u , το μοντέλο κατατάσσει υποψήφια items και επιστρέφει τα πρώτα K . Ένα item θεωρείται σχετικό όταν $r_{u,i} \geq 4$. Η ποιότητα μετριέται με Precision@K, Recall@K, F1@K, HitRate@10 και NDCG@10.

Στην πράξη, το δεύτερο πρόβλημα είναι το πιο κοντά στη χρήση ενός recommender: ο χρήστης δεν ενδιαφέρεται να δει ακριβή πρόβλεψη όλων των ratings, αλλά μία μικρή λίστα πιθανών προτάσεων. Για λόγους υπολογιστικής εφικτότητας και δίκαιης σύγκρισης, οι ranking μετρικές υπολογίζονται σε δειγματισμένο σύνολο υποψηφίων και όχι σε ολόκληρο τον κατάλογο items (βλ. §3.3).

Πίνακας 1.1: Σύνολα δεδομένων Amazon Reviews 2023 που εξετάστηκαν μετά το core filtering.

Dataset	Ρόλος	k	Interactions	Users / Items
Video_Games	κύριο benchmark	5	814 586	94 762 / 25 612
Movies_and_TV	scale case	5	7 441 129	657 203 / 197 943
Digital_Music	sparsity case	2	μικρός πυρήνας	όχι κύριο benchmark

1.2 Κανόνες διαρροής (leakage rule)

Ο βασικός πειραματικός κανόνας είναι ότι το test split προσομοιώνει μελλοντικές αλληλεπιδράσεις που δεν είναι γνωστές κατά την εκπαίδευση. Επομένως, οτιδήποτε μαθαίνει ή υπολογίζει το σύστημα πρέπει να προέρχεται μόνο από το train split.

- Όλα τα feature aggregates (item sentiment, user generosity offsets, category vocabularies, popularity counts), όλα τα propagation edges των γραφικών μοντέλων και κάθε calibration head υπολογίζονται **αποκλειστικά** από το train split.
- Held-out test ακμές **δεν εμφανίζονται ποτέ** σε message passing, node-feature aggregates ή review-sentiment lookups κατά την αξιολόγηση.
- Το review text είναι *interaction-level* feedback και **δεν** χρησιμοποιείται ως item metadata. Αν ένα μοντέλο διάβαζε το review της ίδιας test εγγραφής για την οποία παράγει πρόβλεψη, θα είχε έμμεση πρόσβαση στην απάντηση.

1.3 Επιλογή dataset

Γιατί Video_Games ως κύριο benchmark. Η κατηγορία Video_Games επιβιώνει το αυστηρό 5-core filtering, ενώ παραμένει διαχειρίσιμη για τοπική εκπαίδευση και αξιολόγηση. Με 94 762 χρήστες, 25 612 items και 814 586 αλληλεπιδράσεις μετά το 5-core, είναι αρκετά πυκνή ώστε τα collaborative filtering baselines (SVD, Item-KNN) και τα γραφικά μοντέλα (LightGCN, GraphSAGE) να μπορούν να μάθουν στατιστικά χρήσιμα μοτίβα. Ταυτόχρονα, τα metadata της κατηγορίας παρέχουν πραγματικό content signal για τα content-based μοντέλα.

Γιατί Movies_and_TV ως scale case. Η κατηγορία Movies_and_TV επιβιώνει επίσης το 5-core, αλλά το μέγεθός της είναι πολύ μεγαλύτερο: 7 441 129 αλληλεπιδράσεις, 657 203 χρήστες και 197 943 items. Για αυτό χρησιμοποιείται ως δευτερεύουσα περίπτωση κλιμάκωσης και όχι ως κύριο benchmark. Επιτρέπει να ελεγχθεί ότι το pipeline μπορεί να σταθεί σε μεγαλύτερο dataset, αλλά τα πλήρη graph/review-feature experiments είναι πολύ πιο ακριβά.

Γιατί Digital_Music ως sparsity case. Η κατηγορία Digital_Music είναι χρήσιμη κυρίως για να φανεί το πρόβλημα της αραιότητας. Το strict 5-core πρακτικά την αδειάζει, επειδή το αρχικό dataset έχει πολύ λίγες αξιολογήσεις ανά χρήστη. Ακόμη και με χαλάρωση σε 2-core απομένει μικρός αξιολογήσιμος πυρήνας. Για αυτό δεν χρησιμοποιείται ως βασικό benchmark για collaborative filtering ή γραφικά μοντέλα, αλλά ως παράδειγμα cold-start / sparsity.

Κεφάλαιο 2

Παρουσίαση Προσέγγισης

Η μεθοδολογία ακολουθεί μια σταδιακή αφήγηση: *baseline* content-based και CF μοντέλα, εμπλουτισμένα με content/review-feedback και calibrated hybrid, γραφικοί *recommenders* (LightGCN, GraphSAGE-MSE, GraphSAGE-BPR) πάνω στον train-only γράφο, και τέλος *read-only* ανάλυση γράφου / κοινοτήτων ως ερμηνευτικό υπόβαθρο. Όλες οι μέθοδοι αξιολογούνται με το ίδιο sampled-candidate πρωτόκολλο που περιγράφεται στην §3.

2.1 Content-based filtering

Το content-based μοντέλο βασίζεται στην ιδέα ότι ένας χρήστης είναι πιθανό να ενδιαφερθεί για items που μοιάζουν με όσα έχει ήδη αξιολογήσει θετικά. Για αυτό, πρώτα κατασκευάζεται ένα προφίλ περιεχομένου για κάθε item και στη συνέχεια οι συστάσεις παράγονται με βάση την ομοιότητα ανάμεσα στο υποψήφιο item και στα items του ιστορικού του χρήστη.

Για κάθε item, με κλειδί `parent_asin`, δημιουργείται ένα ενιαίο διάνυσμα χαρακτηριστικών. Το διάνυσμα αυτό περιλαμβάνει:

- transformer text embedding από το ενιαίο κείμενο `title + description + categories`,
- τυποποιημένα αριθμητικά metadata, όπως `price`, `average_rating` και `rating_number`.

Στα πειράματα χρησιμοποιήθηκε ο `ibm-granite/granite-embedding-97m-multilingual-r2`.

Τα διανύσματα κανονικοποιούνται κατά ℓ_2 , ώστε η ομοιότητα δύο items να υπολογίζεται ως cosine similarity μέσω εσωτερικού γινομένου. Για έναν χρήστη u και ένα υποψήφιο item i , η προβλεπόμενη βαθμολογία προκύπτει ως σταθμισμένος μέσος των ratings που έχει δώσει ο χρήστης σε παλαιότερα items j , όπου το βάρος είναι η ομοιότητα του i με το j :

$$\hat{r}(u, i) = \frac{\sum_{(j, r_{uj}) \in H(u), j \neq i} \text{sim}(i, j) r_{uj}}{\sum_{(j, r_{uj}) \in H(u), j \neq i} |\text{sim}(i, j)|}.$$

Αν ο παρονομαστής μηδενιστεί ή αν ο χρήστης/item είναι άγνωστος, η μέθοδος επιστρέφει fallback πρόβλεψη με σειρά προτεραιότητας: item mean $\rightarrow$ user mean $\rightarrow$ global mean. Η τελική τιμή περιορίζεται στο διάστημα $[1, 5]$.

Στο κείμενο δεν εφαρμόζεται κλασική NLP προεπεξεργασία όπως stemming, lemmatization ή stopwords removal. Αυτές οι τεχνικές ταιριάζουν κυρίως σε bag-of-words ή TF-IDF αναπαραστάσεις, ενώ τα transformer embeddings έχουν εκπαιδευτεί πάνω σε φυσικό κείμενο και αξιοποιούν τη σειρά και το συμφραζόμενο των λέξεων.

Στο Video_Games, το plain content-based μοντέλο λειτουργεί ως χρήσιμο baseline, αλλά δεν είναι αρκετό από μόνο του: πετυχαίνει $F1@10 = 0.0675$, χαμηλότερα από το ισχυρό popularity baseline (0.1284, Πίνακας 3.3). Αυτό δείχνει ότι η σημασιολογική ομοιότητα των metadata βοηθά, αλλά δεν αντικαθιστά το collaborative signal που προκύπτει από τις αξιολογήσεις των χρηστών.

2.2 Item-KNN collaborative filtering

Το Item-KNN είναι ένα κλασικό collaborative filtering μοντέλο που βασίζεται αποκλειστικά στον πίνακα αξιολογήσεων. Δεν χρησιμοποιεί τίτλους, περιγραφές, κατηγορίες ή άλλα metadata. Η βασική υπόθεση είναι ότι δύο items είναι παρόμοια όταν αξιολογούνται με παρόμοιο τρόπο από τους ίδιους ή παρόμοιους χρήστες.

Στην υλοποίηση χρησιμοποιείται η μέθοδος `surprise.KNNWithMeans` σε item-based mode (`user_based=False`) [3]. Για κάθε υποψήφιο item, το μοντέλο αναζητά γειτονικά items που ο χρήστης έχει ήδη αξιολογήσει και προβλέπει τη βαθμολογία με βάση τις αξιολογήσεις αυτών των γειτόνων, διορθωμένες ως προς τους μέσους όρους τους.

Στο Streamlit app εκτίθενται τρεις παραλλαγές μετρικής ομοιότητας: `msd`, `cosine` και `pearson`. Στα κύρια offline runs διατηρείται η προεπιλογή του Surprise, δηλαδή `msd`, ώστε τα αποτελέσματα να είναι συνεπή με τα αρχικά experiments.

Ο βασικός περιορισμός του Item-KNN είναι υπολογιστικός. Ο πίνακας item-item ομοιοτήτων έχει κόστος μνήμης τάξης $O(n_{\text{items}}^2)$. Για αυτό, στα μεγάλα runs το evaluate υποστηρίζει τη σημαία `--no-knn`, ώστε να παραλείπεται το KNN όταν το πλήθος των items κάνει τον πλήρη πίνακα ομοιοτήτων κοστοβόρο.

2.3 SVD / matrix factorization

Το SVD αποτελεί το βασικό matrix factorization μοντέλο της εργασίας και χρησιμοποιείται ως ισχυρό collaborative filtering baseline. Σε αντίθεση με το content-based μοντέλο, δεν αξιοποιεί metadata ή κείμενο. Μαθαίνει μόνο από τον πίνακα αξιολογήσεων, δηλαδή από το ποιοι χρήστες αξιολόγησαν ποια items και με ποια βαθμολογία.

Η βασική ιδέα είναι ότι τόσο οι χρήστες όσο και τα items μπορούν να αναπαρασταθούν σε έναν κοινό λανθάνοντα χώρο διάστασης d . Κάθε χρήστης u αποκτά ένα διάνυσμα $p_u \in \mathbb{R}^d$ και κάθε item i ένα διάνυσμα $q_i \in \mathbb{R}^d$. Το εσωτερικό γινόμενο $p_u^\top q_i$ εκφράζει πόσο ταιριάζει ο χρήστης με το item. Επιπλέον, το μοντέλο μαθαίνει bias όρους b_u και b_i , ώστε να αποτυπώνει χρήστες που βαθμολογούν συστηματικά πιο αυστηρά ή πιο γενναιόδωρα, καθώς και items που τείνουν να λαμβάνουν υψηλότερες ή χαμηλότερες βαθμολογίες [2].

Η πρόβλεψη έχει τη μορφή:

$$\hat{r}(u, i) = \mu + b_u + b_i + p_u^\top q_i,$$

όπου μ είναι η μέση βαθμολογία του train split. Η εκπαίδευση ελαχιστοποιεί regularized squared error πάνω στις γνωστές train αξιολογήσεις, και η τελική πρόβλεψη περιορίζεται στο διάστημα $[1, 5]$. Στην υλοποίηση χρησιμοποιείται το `surprise.SVD`.

Στα αποτελέσματα, το SVD είναι το ισχυρότερο classic baseline ως προς RMSE στο Video_Games (RMSE = 1.1337, Πίνακας 3.3). Ωστόσο, το sampled-candidate ranking του είναι χαμηλότερο (F1@10 = 0.0543), επειδή η αντικειμενική συνάρτηση του SVD βελτιστοποιεί ακρίβεια βαθμολογίας και όχι απευθείας top- K κατάταξη. Αυτό εξηγεί γιατί ένα μοντέλο μπορεί να είναι πολύ καλό στο rating prediction αλλά όχι απαραίτητα το καλύτερο recommender για λίστες προτάσεων.

2.4 Weighted hybrid και calibrated hybrid

Το υβριδικό μοντέλο συνδυάζει δύο διαφορετικές πηγές σήματος: collaborative filtering και content-based filtering. Η απλούστερη μορφή είναι ένας σταθμισμένος μέσος των δύο προβλέψεων:

$$\hat{r}_{\text{hybrid}}(u, i) = \alpha \hat{r}_{\text{CF}}(u, i) + (1 - \alpha) \hat{r}_{\text{content}}(u, i), \quad \alpha \in [0, 1].$$

Η παράμετρος α ελέγχει πόσο βάρος δίνεται στο collaborative μοντέλο: όταν $\alpha = 1$, το hybrid ισοδυναμεί με το CF μοντέλο, ενώ όταν $\alpha = 0$, ισοδυναμεί με το content-based μοντέλο. Στα πειράματα, το α συντονίζεται σε train-only validation slice.

Στην πράξη, οι δύο συνιστώσες μπορεί να παράγουν scores με διαφορετική κλίμακα και διασπορά. Αν συνδυαστούν απευθείας, η συνιστώσα με μεγαλύτερο εύρος τιμών μπορεί να επηρεάσει δυσανάλογα το τελικό score. Για αυτό υλοποιείται και calibrated hybrid, όπου κάθε συνιστώσα πρώτα κανονικοποιείται με βάση τη μέση τιμή και την τυπική απόκλιση των προβλέψεων της στο train split:

$$z_c = \frac{r_c - \mu_c}{\sigma_c}.$$

Στη συνέχεια, το κανονικοποιημένο score επανακλιμακώνεται γύρω από τη μέση βαθμολογία του train split:

$$\tilde{r}_c = \mu_{\text{train}} + \sigma_{\text{train}}^{(\text{rating})} z_c.$$

Οι calibrated συνιστώσες συνδυάζονται με τον ίδιο σταθμισμένο τύπο του weighted hybrid.

Στο video_games, όταν το α επιλέγεται με βάση το RMSE, η βέλτιστη τιμή είναι πολύ κοντά στο 1.0. Αυτό σημαίνει ότι το απλό weighted hybrid δίνει σχεδόν όλο το βάρος στο SVD και, επομένως, έχει πρακτικά την ίδια συμπεριφορά με το collaborative μοντέλο (Πίνακας 3.3). Το alpha sweep του calibrated hybrid (Πίνακας 3.4) δείχνει το βασικό trade-off: μικρότερο α αυξάνει τη συμβολή του content-based σήματος και βελτιώνει το F1@10, αλλά ταυτόχρονα χειροτερεύει το RMSE. Άρα ο κατάλληλος συνδυασμός εξαρτάται από τον στόχο: ακριβής πρόβλεψη βαθμολογίας ή καλύτερη top- K κατάταξη.

2.5 Εμπλουτισμένο content με review-feedback

Το plain content-based μοντέλο χρησιμοποιεί κυρίως σημασιολογική ομοιότητα με βάση τίτλο, περιγραφή, κατηγορίες και αριθμητικά metadata. Το content_enriched

επεκτείνει αυτή την ιδέα προσθέτοντας πιο δομημένα content features και train-only σήματα από τα review texts. Στόχος δεν είναι να «διαβάσει» τα reviews του test set, αλλά να αξιοποιήσει συγκεντρωτικά μοτίβα από το train split, όπως το αν ένα item λαμβάνει θετικό ή αρνητικό feedback στα διαθέσιμα training reviews.

Για κάθε item δημιουργείται ένα εμπλουτισμένο feature vector που περιλαμβάνει:

- Transformer embedding του **title + description**. Σε αυτή την εκδοχή οι κατηγορίες δεν ενσωματώνονται στο κείμενο, επειδή αναπαρίστανται ξεχωριστά ως δομημένο feature.
- Multi-hot αναπαράσταση φιλτραρισμένων κατηγοριών. Αφαιρούνται generic roots, όπως **Video Games**, ώστε το μοντέλο να κρατά πιο ειδικές κατηγορίες, π.χ. πλατφόρμες ή είδη προϊόντων.
- Τυποποιημένα αριθμητικά metadata (**price, average_rating** και **rating_number**)
- Train-only item-sentiment aggregates, τα οποία προκύπτουν από DistilBERT-SST-2 [8] πάνω στα review texts του train split.
- Train-only user-generosity offset (**user_rating_minus_sentiment_gap**), ώστε να αποτυπώνεται αν ένας χρήστης τείνει να βαθμολογεί πιο αυστηρά ή πιο γενναιόδωρα σε σχέση με το sentiment των reviews του.

Η ίδια υποδομή κατασκευής item features χρησιμοποιείται και από το GraphSAGE, ώστε τα content-based και graph-based μοντέλα να στηρίζονται σε συνεπείς αναπαραστάσεις. Αυτό επιτρέπει πιο καθαρή σύγκριση: όταν αλλάζει το μοντέλο, δεν αλλάζει αυθαίρετα και ο τρόπος με τον οποίο αναπαρίσταται το item.

Στο sentiment ablation (Πίνακας 3.5), η προσθήκη sentiment βελτιώνει το ranking του **content_enriched** ($F1@10$: 0.1047 $\rightarrow$ 0.1250), αλλά χειροτερεύει το **MAE** (0.7917 $\rightarrow$ 0.8258). Επομένως, το review-feedback δεν αντιμετωπίζεται ως καθολική βελτίωση. Είναι χρήσιμο ως ranking-oriented σήμα για το εμπλουτισμένο content μοντέλο, αλλά πρέπει να αξιολογείται ξεχωριστά ανά μοντέλο και στόχο.

2.6 Random και popularity baselines

Για να ερμηνευθούν σωστά τα αποτελέσματα, χρησιμοποιούνται δύο απλά baselines. Το πρώτο είναι το **random baseline**, το οποίο αποδίδει ομοιόμορφα τυχαίο score σε κάθε υποψήφιο item, με ντετερμινιστικό seed 42. Λειτουργεί ως κατώτατο σημείο αναφοράς: ένα χρήσιμο recommender πρέπει να το ξεπερνά καθαρά.

Το δεύτερο είναι το **popularity baseline**. Σε αυτό, το score ενός item ισούται με το πλήθος των train αλληλεπιδράσεών του και είναι ίδιο για όλους τους χρήστες. Δεν υπάρχει personalization, όμως το baseline είναι ιδιαίτερα σημαντικό, επειδή σε sparse datasets τα δημοφιλή items εμφανίζονται συχνά ως ισχυρές προτάσεις στο sampled-ranking protocol.

Στο **Video Games**, το popularity baseline είναι το ισχυρότερο μη-νευρωνικό sampled-ranking baseline (Πίνακας 3.3). Για αυτό, κάθε πιο σύνθετο μοντέλο πρέπει να συγκρίνεται πρώτα με το random και το popularity baseline πριν θεωρηθεί ότι προσφέρει ουσιαστικό κέρδος.

2.7 Γραφικές μέθοδοι συστάσεων

Οι γραφικές μέθοδοι μοντελοποιούν το πρόβλημα συστάσεων ως γράφο χρηστών-items. Κάθε χρήστης και κάθε item είναι κόμβος, ενώ κάθε γνωστή αξιολόγηση αντιστοιχεί σε ακμή. Αυτή η αναπαράσταση επιτρέπει στα μοντέλα να αξιοποιήσουν όχι μόνο μεμονωμένες βαθμολογίες, αλλά και τη δομή γειτονιάς: ποιοι χρήστες συνδέονται με ποια items και ποια items συνδέονται έμμεσα μέσω κοινών χρηστών.

2.7.1 Κατασκευή train-only γράφου χρήστη-item

Όλα τα γραφικά recommender μοντέλα δουλεύουν πάνω στον ίδιο *train-only* διμερικό γράφο χρήστη-item. Ο γράφος κατασκευάζεται από το `src.graph.build` και χρησιμοποιείται από τα `LightGCN`, `GraphSAGE` και `GraphSAGE-BPR`. Test ακμές δεν εισάγονται ποτέ στον γράφο, ώστε να μην υπάρξει διαρροή πληροφορίας από το held-out split.

Οι κόμβοι χρηστών αριθμούνται στο διάστημα $[0, n_u)$ και οι κόμβοι items στο διάστημα $[n_u, n_u + n_i)$, με σταθερό `item_offset` = n_u . Η κατασκευή διατηρεί δύο όψεις των train ακμών:

- **Observed edges:** όλες οι train αλληλεπιδράσεις μαζί με το πραγματικό rating τους. Αυτές χρησιμοποιούνται από το `GraphSAGE-MSE`, όπου το rating είναι το label της ακμής.
- **Positive-only edges:** το υποσύνολο των train ακμών με $r_{u,i} \geq 4$. Αυτές χρησιμοποιούνται από τα `BPR` μοντέλα, δηλαδή το `LightGCN` και το `GraphSAGE-BPR`.

Με αυτόν τον σχεδιασμό, τα graph models εκπαιδεύονται μόνο πάνω σε γνωστή ιστορική πληροφορία. Οι held-out test ακμές χρησιμοποιούνται αποκλειστικά για αξιολόγηση και δεν συμμετέχουν σε message passing ή σε node-feature aggregates.

2.7.2 LightGCN

Το `LightGCN` είναι το καθαρά collaborative graph μοντέλο της εργασίας. Δεν χρησιμοποιεί node features, κείμενο ή metadata. Μαθαίνει μόνο από τη δομή του train-only γράφου χρήστη-item. Κάθε χρήστης και κάθε item ξεκινά με ένα trainable embedding, και το message passing διαδίδει πληροφορία μέσα από τις positive-only ακμές.

Στα πειράματα χρησιμοποιείται wrapper γύρω από το `torch_geometric.nn.models.LightGCN` [5], με `embedding_dim` = 64 και `num_layers` = 2. Η εκπαίδευση γίνεται με BPR pairwise ranking [4]. Για κάθε χρήστη, το μοντέλο συγκρίνει ένα θετικό item i με ένα ή περισσότερα αρνητικά δειγματοσιμμένα items j :

$$\mathcal{L}_{\text{BPR}}(u, i, j) = \text{softplus}(\langle h_u, h_j \rangle - \langle h_u, h_i \rangle).$$

Ο στόχος είναι το θετικό item να έχει υψηλότερο score από το αρνητικό. Το `num_negatives` είναι ρυθμιζόμενο και στα checkpoints δοκιμάστηκε από 1 έως 4.

Επειδή το BPR παράγει ranking scores και όχι απευθείας προβλέψεις rating, χρησιμοποιείται ξεχωριστό calibration head για τις RMSE / MAE μετρικές. Συγκεκριμένα, σε train-derived validation slice fit-άρεται γραμμική απεικόνιση:

$$\hat{r}(u, i) = \beta \cdot \langle h_u, h_i \rangle + \gamma,$$

και η τελική τιμή περιορίζεται στο διάστημα $[1, 5]$.

Στο `Video_Games`, το `LightGCN` είναι ο ισχυρότερος sampled top- K ranker. Το καλύτερο checkpoint φτάνει περίπου το 58.5% του oracle `F1@10` (Πίνακες 3.6 και 3.8).

2.7.3 GraphSAGE με MSE

Το GraphSAGE χρησιμοποιείται ως υβριδικό graph μοντέλο, επειδή μπορεί να συνδυάσει τη δομή του γράφου με node features. Σε αντίθεση με το `LightGCN`, δεν βασίζεται μόνο στις ταυτότητες των κόμβων. Τα item nodes λαμβάνουν features από το εμπλουτισμένο content representation:

title/description embedding $\oplus$ filtered categories $\oplus$ numeric metadata $\oplus$ train-only item sentiment.

Τα user nodes λαμβάνουν train-only behavioural aggregates, όπως πλήθος αξιολογήσεων, μέση βαθμολογία και προαιρετικά sentiment/generosity offsets.

Η αρχιτεκτονική αποτελείται από `SAGEConv` layers [6] με `hidden_dim = 64` και $n_{\text{layers}} = 2$. Μετά το message passing, ένα MLP edge head λαμβάνει το διάνυσμα $[h_u \parallel h_i]$ και προβλέπει rating. Η εκπαίδευση γίνεται με MSE πάνω στις observed train ακμές:

$$\mathcal{L}_{\text{MSE}} = \frac{1}{|B|} \sum_{(u,i,r) \in B} (\text{MLP}([h_u \parallel h_i]) - r)^2.$$

Το rating δεν είναι feature εισόδου· χρησιμοποιείται μόνο ως label της train ακμής.

Το GraphSAGE-MSE είναι καλύτερο για rating regression από το `LightGCN`, αλλά πιο αδύναμο στο sampled ranking. Αυτό είναι αναμενόμενο, επειδή η αντικειμενική του βελτιστοποιεί αριθμητική πρόβλεψη rating και όχι απευθείας top- K κατάταξη.

2.7.4 GraphSAGE-BPR

Το GraphSAGE-BPR κρατά την ίδια ιδέα του GraphSAGE, δηλαδή message passing πάνω στον γράφο με node features, αλλά αλλάζει την αντικειμενική συνάρτηση. Αντί να εκπαιδεύεται με MSE πάνω σε ratings, εκπαιδεύεται με BPR pairwise ranking πάνω στις positive-only ακμές. Έτσι, το μοντέλο γίνεται πιο κοντά στον στόχο του top- K recommendation.

Για το BPR scoring χρησιμοποιείται το εσωτερικό γινόμενο των τελικών user/item embeddings. Με αυτόν τον τρόπο, το GraphSAGE-BPR συνδυάζει:

- το content signal των item/user features,
- το collaborative signal του train-only γράφου,
- και ranking-aware εκπαίδευση μέσω BPR.

Η υλοποίηση επιτρέπει επίσης feature ablation μέσω της παραμέτρου `feature_set`, με επιλογές όπως `full`, `no_text`, `no_sentiment`, `metadata_only` και `structure_only`. Έτσι ελέγχεται εμπειρικά ποια ομάδα features συνεισφέρει πραγματικά στο ranking.

Στα αποτελέσματα, το `no_sentiment` ξεπερνά το `full` στο sampled `F1@10` (Πίνακας 3.7). Αυτό δείχνει ότι το sentiment/generosity signal είναι θορυβώδες για το GraphSAGE-BPR στο συγκεκριμένο training budget. Παρά τη βελτίωση σε σχέση με το GraphSAGE-MSE ως προς το ranking, το GraphSAGE-BPR παραμένει πίσω από το `LightGCN`.

Κεφάλαιο 3

Πειραματική Μελέτη


3.1 Διοχέτευση προεπεξεργασίας

Η διοχέτευση προεπεξεργασίας εφαρμόζεται ομοιόμορφα και ντετερμινιστικά:

1. Απόρριψη μη έγκυρων γραμμών (ανεπαρκή πεδία `user_id` / `parent_asin` / `rating`).
2. Αποδιπλοποίηση των ζευγών (`user_id`, `parent_asin`) με διατήρηση του πιο πρόσφατου `timestamp`.
3. Dataset-specific k-core filter: $k = 5$ για `Video_Games` και `Movies_and_TV`, $k = 2$ για `Digital_Music` (όπου το strict 5-core αδειάζει το dataset).
4. Per-user χρονολογικό 80/20 train/test split, seed 42. Το `train` κάθε χρήστη προηγείται χρονολογικά των αντίστοιχων held-out `test` εγγραφών του ίδιου χρήστη.
5. Χειρισμός missing metadata (null `price` / `description` – με flags).
6. Ευθυγράμμιση metadata στο `parent_asin`.

Πίνακας 3.1: Επιβίωση δεδομένων στη διοχέτευση προεπεξεργασίας του `Video_Games`.


Στάδιο	Τιμή
Raw reviews	4 624 615
Μετά την αποδιπλοποίηση	4 555 500
Μετά το 5-core	814 586
Χρήστες πριν	2 766 656
Χρήστες μετά	94 762
Items πριν	137 249
Items μετά	25 612
Train αλληλεπιδράσεις	656 373
Test αλληλεπιδράσεις	158 213
Sparsity πριν	0.999988
Sparsity μετά	0.999664
% rating ≥ 4 μετά το core	80.39%



Σχήμα 3.1: Διοχέτευση προεπεξεργασίας για το Video_Games: raw reviews, αποδιπλοποίηση και 5-core filtering.

3.2 Κατανομή βαθμολογιών και σπανιότητα

Μετά το 5-core, περίπου 80% των ratings είναι θετικά (≥ 4), με σαφή κλίση προς το 5-star. Δεν εφαρμόζουμε resampling ή class-balancing: η εργασία rating-prediction απαιτεί τη φυσική κατανομή, ενώ για ranking η σχετικότητα είναι binary ($\text{rating} \geq 4$) και κληρονομεί άμεσα τη φυσική κλίση του implicit feedback. Η σπανιότητα είναι ισχυρή ακόμη και μετά το core (≈ 0.9997), οπότε τα ranking αποτελέσματα ερμηνεύονται πάντα σε σχέση με τα random / popularity baselines και το oracle ceiling.



Σχήμα 3.2: Κατανομή των ratings στο Video_Games μετά το 5-core filtering.

3.3 Μετρικές αξιολόγησης

Rating prediction. Επί του test split $T = \{(u, i, r)\}$:

$$\text{RMSE} = \sqrt{\frac{1}{|T|} \sum_{(u,i,r) \in T} (r - \hat{r}(u, i))^2}, \quad \text{MAE} = \frac{1}{|T|} \sum_{(u,i,r) \in T} |r - \hat{r}(u, i)|.$$

Sampled-candidate top- K ranking. Για κάθε χρήστη u , ορίζουμε ως σχετικά $R(u)$ τα test items του u με $r_{u,i} \geq 4$, δηλαδή items που έχουν βαθμολογία τουλάχιστον 4 αστέρια στο held-out test split. Δημιουργούμε σύνολο υποψηφίων

$$C(u) = R(u) \cup N(u),$$

όπου $N(u)$ είναι $N = 100$ τυχαία items εκτός του $\text{train}(u) \cup \text{test}(u)$, δειγματοσιμμένα με fixed seed 42. Το ίδιο $C(u)$ τροφοδοτείται σε όλα τα μοντέλα. Το $\text{TopK}(u)$ είναι τα $K = 10$ υψηλότερα-βαθμολογημένα items στο $C(u)$ με score του μοντέλου. Τότε:

$$\begin{aligned} \text{P@K}(u) &= \frac{|\text{TopK}(u) \cap R(u)|}{K}, & \text{R@K}(u) &= \frac{|\text{TopK}(u) \cap R(u)|}{|R(u)|}, \\ \text{F1@K}(u) &= \frac{2 \cdot \text{P@K}(u) \cdot \text{R@K}(u)}{\text{P@K}(u) + \text{R@K}(u)}, & \text{HitRate@K}(u) &= \mathbf{1}[|\text{TopK}(u) \cap R(u)| > 0]. \end{aligned}$$

NDCG@K (binary relevance).

$$\begin{aligned} \text{DCG@K}(u) &= \sum_{i \in \text{TopK}(u) \cap R(u)} \frac{1}{\log_2(\text{rank}(i) + 1)}, & \text{IDCG@K}(u) &= \sum_{i=1}^{\min(K, |R(u)|)} \frac{1}{\log_2(i + 1)}, \\ \text{NDCG@K}(u) &= \frac{\text{DCG@K}(u)}{\text{IDCG@K}(u)}. \end{aligned}$$

Συναθροισμός. Όλες οι ranking μετρικές αναφέρονται ως μέσος ανά χρήστη (*mean-of-means*), χωρίς στάθμιση με το πλήθος των σχετικών items του χρήστη. Οι oracle-normalized στήλες (π.χ. $\text{F1}/\text{oracleF1}$) χρησιμοποιούν επίσης mean-of-means στον αριθμητή και στον παρονομαστή, για να αποφευχθεί δυσανάλογη στάθμιση από χρήστες με πολλά relevant items.

3.4 Sampled-candidate πρωτόκολλο και caveats

Επισημαίνουμε ρητά:

- Όλες οι ranking μετρικές είναι **sampled-candidate**, όχι full-catalog. Δηλαδή τα τελικά νούμερα δεν είναι άμεσα συγκρίσιμα με μετρικές άλλων εργασιών που χρησιμοποιούν διαφορετικό candidate sampling ή full-catalog ranking.
- Το seed 42, το $N = 100$ και ο cap --max-eval-users είναι ίδια για όλα τα μοντέλα στο ίδιο run.
- Στις αναφερόμενες μετρήσεις για το video_games το $n_{\text{eval users}}$ είναι 79 248 (το πλήθος χρηστών με τουλάχιστον ένα σχετικό test item).

Πίνακας 3.4: Alpha sweep του `calibrated_hybrid` ($\alpha \cdot \text{SVD} + (1 - \alpha) \cdot \text{content_enriched, video_games}$).

α	RMSE	MAE	P@10	R@10	F1@10
0.75	1.1501	0.7698	0.0556	0.3330	0.0896
0.60	1.1596	0.7664	0.0588	0.3562	0.0950
0.50	1.1737	0.7679	0.0619	0.3789	0.1003
0.40	1.1938	0.7722	0.0662	0.4093	0.1076

3.5 Oracle ceiling

Για το χρονολογικό 80/20 split του `Video_Games`, ο διάμεσος αριθμός σχετικών test items ανά χρήστη είναι μόλις 1. Συνεπώς το raw P@10 είναι δομικά πεπερασμένο από πάνω: ένας τέλειος ranker δεν μπορεί να τοποθετήσει περισσότερα από $\min(K, |R(u)|)$ θετικά items στο top- K . Αυτό το «oracle ceiling» πρέπει να συνοδεύει κάθε ερμηνεία χαμηλών raw P/R/F1 τιμών.

Πίνακας 3.2: Oracle ceiling για το `Video_Games` 80/20 (sampled-candidate @10).

P*@10	R*@10	F1*@10	HR*@10	NDCG*@10
0.1552	0.9990	0.2551	1.0000	1.0000


Το cohort είναι `video_games / 80/20` με 79 248 evaluable users. Στις αναφερόμενες audit μετρικές (Πίνακας 3.8) οι στήλες X/X^* είναι λόγοι των mean-of-means τιμών προς τα αντίστοιχα oracle ceilings.

3.6 Αποτελέσματα: advanced run


Όλα τα νούμερα του Πίνακα 3.3 προέρχονται από το ίδιο sampled-candidate run στο `video_games` (5-core, 80/20, $n_{\text{eval users}} = 79\,248$). Ο RMSE-tuned hybrid χρησιμοποιεί $\alpha = 1.0$, οπότε στην πράξη συμπίπτει με το SVD. Η γραμμή `hybrid` στον Πίνακα 3.3 αντιστοιχεί σε αυτή τη RMSE-tuned επιλογή. Η γραμμή `calibrated_hybrid` αντιστοιχεί στην αποθηκευμένη calibrated παραλλαγή με $\alpha = 0.5$, ώστε να είναι συνεπής με τις audit μετρικές του Πίνακα 3.8.

Πίνακας 3.3: Advanced run στο `video_games` (5-core, 80/20, $n_{\text{eval users}} = 79\,248$, $\alpha = 1.0$ για τον RMSE-tuned hybrid).

Model	RMSE	MAE	P@10	R@10	F1@10
content	1.4757	1.0580	0.0399	0.2856	0.0675
svd	1.1337	0.8173	0.0335	0.2100	0.0543
hybrid	1.1337	0.8173	0.0335	0.2100	0.0543
random	1.2569	0.9780	0.0152	0.0975	0.0249
popularity	1.2270	0.9059	0.0776	0.5108	0.1284
content_enriched	1.2660	0.8258	0.0755	0.5014	0.1250
calibrated_hybrid	1.1737	0.7679	0.0619	0.3789	0.1003



Σχήμα 3.3: Σύγκριση RMSE και MAE για τα βασικά και εμπλουτισμένα μοντέλα.



Σχήμα 3.4: Σύγκριση sampled-candidate ranking μετρικών P@10, R@10 και F1@10.

3.7 Αποτελέσματα: graph checkpoint eval


Όλα τα γραφικά checkpoints αξιολογούνται μέσω των ειδικών `evaluate_*_checkpoint` entrypoints, χωρίς επανεκπαίδευση, στο ίδιο σύνολο sampled υποψηφίων με τα classic baselines. Στον Πίνακα 3.6, LGCN σημαίνει LightGCN, GS-MSE σημαίνει GraphSAGE-MSE, GS-BPR σημαίνει GraphSAGE-BPR, n δηλώνει num_negatives, wd weight decay.

Πίνακας 3.6: Graph checkpoint evaluation στο video_games (sampled-candidate @10, $n_{eval\ users} = 79\,248$).

Model	RMSE	MAE	P@10	R@10	F1@10
LGCN 10ep / n1	1.2472	0.9556	0.0880	0.5755	0.1454
LGCN 20ep / n1	1.2459	0.9589	0.0882	0.5782	0.1458
LGCN 40ep / n4	1.2433	0.9598	0.0901	0.5923	0.1491
LGCN 40ep / n4 / wd	1.2433	0.9598	0.0902	0.5928	0.1492
GS-MSE 10ep	1.1613	0.7640	0.0235	0.1488	0.0380
GS-MSE 20ep	1.1695	0.7388	0.0546	0.3483	0.0891
GS-BPR 20ep / n4	1.2559	0.9814	0.0550	0.3573	0.0906
GS-BPR 20ep / n4 / no-sent	1.2566	0.9782	0.0563	0.3722	0.0934

Πίνακας 3.5: Sentiment ablation στο `video_games` ($\alpha = 0.6$, ίδια sampled candidates, ίδιο train slice, ίδιο vocabulary κατηγοριών).

Model	RMSE	MAE	P@10	R@10	F1@10
content_enriched_with_sentiment	1.2660	0.8258	0.0755	0.5014	0.1250
content_enriched_no_sentiment	1.1777	0.7917	0.0627	0.4278	0.1047



Σχήμα 3.5: F1@10 των graph checkpoints στο ίδιο sampled-candidate πρωτόκολλο.

Πίνακας 3.7: GraphSAGE-BPR feature ablation στο `video_games` (`graph.epochs = 10`, $n_{\text{eval users}} \approx 79\,248$).

feature_set	RMSE	MAE	P@10	R@10	F1@10
full	1.2554	0.9858	0.0339	0.2142	0.0556
no_text	1.2589	0.9689	0.0211	0.1326	0.0342
no_sentiment	1.2556	0.9826	0.0427	0.2706	0.0699
metadata_only	1.2561	0.9809	0.0211	0.1363	0.0346

3.8 Audit μετρικές

Οι audit στήλες $X/\text{oracle}X$ ερμηνεύονται έναντι του Πίνακα 3.2: ένας τέλειος ranker θα έπιανε λόγο 1.0 σε κάθε στήλη.

Πίνακας 3.8: Audit μετρικές στο `video_games`, ίδιο sampled-candidate πρωτόκολλο.

Model	HR@10	NDCG@10	P/P*	R/R*	F1/F1*
popularity	0.5902	0.3360	0.4999	0.5113	0.5032
svd	0.2829	0.1303	0.2157	0.2102	0.2130
content_enriched	0.5405	0.4599	0.4861	0.5019	0.4901
calibrated_hybrid	0.4516	0.3484	0.3986	0.3793	0.3932
LGCN 40ep/n4/wd	0.6673	0.4148	0.5811	0.5934	0.5849
GS-BPR 20ep/no-sent	0.4574	0.2274	0.3629	0.3726	0.3660

3.9 Leave-last-out έλεγχος


Στο leave-last-out protocol απομονώνεται ένα τελευταίο test item ανά χρήστη και ένα δεύτερο-τελευταίο για validation. Με ένα μόνο σχετικό test item ανά χρήστη ισχύει $R@10 = \text{HitRate}@10$. το oracle $P@10$ είναι 0.1000 και το oracle $F1@10$ είναι 0.1818. Οι γραμμές LightGCN εδώ προέρχονται από checkpoint εκπαιδευμένο στα leave-last-out suffixed artifacts, όχι από το 80/20 checkpoint.

Πίνακας 3.9: Leave-last-out στο video_games (1 σχετικό test item ανά χρήστη, οπότε $R@10 = \text{HitRate}@10$).

Model	RMSE	MAE	P@10	HR/R	F1@10	NDCG	F1/F1*
popularity	1.2676	0.9310	0.0502	0.5017	0.0912	0.3054	0.5017
content_enriched	1.2634	0.8378	0.0469	0.4686	0.0852	0.4069	0.4686
calibrated_hybrid	1.2257	0.8104	0.0386	0.3863	0.0702	0.3388	0.3863
LGCN 20ep/n4/wd	1.2811	0.9875	0.0530	0.5301	0.0964	0.3400	0.5301

3.10 Ανάλυση Γράφων


Πέρα από την αξιολόγηση των recommender models, εξετάστηκε και η δομή του γράφου που προκύπτει από κοινές θετικές αξιολογήσεις. Το item-item co-rating projection συνδέει δύο items όταν έχουν αξιολογηθεί θετικά από αρκετούς κοινούς χρήστες. Με διαφορετικά thresholds στο min_shared_users, ο γράφος γίνεται πιο αραιός ή πιο πυκνός, επηρεάζοντας το πλήθος ακμών, το μέγεθος της μεγαλύτερης συνιστώσας και την καθαρότητα των κοινοτήτων.



Σχήμα 3.6: Κλίμακα των item-item co-rating projections για διαφορετικά thresholds.

Η ανάλυση κοινοτήτων δεν χρησιμοποιείται ως feature των recommender models, αλλά ως εργαλείο ερμηνείας της δομής του dataset. Για να ελεγχθεί αν οι κοινότητες που προκύπτουν από το item-item co-rating projection έχουν σημασιολογικό νόημα, συγκρίνονται με τις φιλτραρισμένες κατηγορίες των metadata. Η ευθυγράμμιση μετريέται

με purity και normalized mutual information (NMI): υψηλότερες τιμές δηλώνουν ότι οι graph communities αντιστοιχούν περισσότερο σε συνεκτικές κατηγορίες προϊόντων.



Σχήμα 3.7: Ευθυγράμμιση κοινοτήτων με τις φιλτραρισμένες κατηγορίες metadata.

3.11 Σχολιασμός

1. Το **SVD** κερδίζει το RMSE μεταξύ των classic baselines (RMSE = 1.1337 στον Πίνακα 3.3), αλλά είναι αδύναμο στο sampled top- K ranking (F1@10 = 0.0543). Δύο διαφορετικά objectives, δύο διαφορετικοί νικητές.
2. Το **popularity** είναι έκπληξη-ισχυρό sampled-ranking baseline (F1@10 = 0.1284). Συνεπώς, πριν χαρακτηριστεί ένα μοντέλο «καλό» στο ranking, πρέπει να συγκριθεί πρώτα με τη γραμμή popularity.
3. Το **content_enriched** βελτιώνει το plain content από F1@10 = 0.0675 σε 0.1250 και πλησιάζει το popularity, ενώ ταυτόχρονα βελτιώνει σαφώς το MAE του plain content. Άρα η εμπλουτισμένη αναπαράσταση βοηθάει και στο ranking και στην πιστότητα ratings.
4. Ο απλός **weighted hybrid** με RMSE-tuned $\alpha = 1.0$ καταρρέει στο SVD (η γραμμή hybrid στον Πίνακα 3.3 είναι ταυτόσημη). Το alpha sweep του calibrated hybrid (Πίνακας 3.4) δείχνει το αναμενόμενο trade-off: χαμηλότερο α βελτιώνει F1@10 εις βάρος του RMSE.
5. Το **LightGCN** είναι ο ισχυρότερος top- K ranker στο πείραμα: F1@10 = 0.1492 στο best checkpoint (40ep / neg4 / wd1e-5, Πίνακας 3.6) και F1/oracleF1 = 0.5849 (Πίνακας 3.8), δηλαδή φτάνει περίπου 58.5% (~58.5%) του oracle ceiling.
6. Το **GraphSAGE-MSE** είναι το δυνατότερο rating regression γραφικό μοντέλο (RMSE $\approx$ 1.1613, MAE $\approx$ 0.7640 στο 10ep checkpoint) αλλά αδύναμο στο ranking. Το **GraphSAGE-BPR** βελτιώνει το ranking του GraphSAGE αλλά δεν ξεπερνά το LightGCN.

7. Το **sentiment / review-feedback** βοηθάει το **content_enriched** ranking ($F1@10$ $0.1047 \rightarrow 0.1250$, Πίνακας 3.5) αλλά είναι *θορυβώδες* στο GraphSAGE-BPR -- το **no_sentiment** **feature_set** ξεπερνά το **full** (Πίνακας 3.7). Επομένως το **sentiment** αντιμετωπίζεται ως προαιρετικό feature στόχου-ranking, όχι ως καθολικό κέρδος.
8. Οι χαμηλά εμφανιζόμενες $P@10$ τιμές είναι *εν μέρει δομικές*: ο διάμεσος αριθμός σχετικών items ανά χρήστη είναι ≈ 1 , οπότε το oracle $P@10$ είναι 0.1552 (Πίνακας 3.2). Οι ratio-στήλες του Πίνακα 3.8 αφαιρούν αυτή την εξάρτηση.
9. Δεν συγκρίνουμε raw $F1@10$ ή $NDCG@10$ ευθέως με άλλες εργασίες ή datasets, εκτός εάν η μέθοδος sampling υποψηφίων και το split protocol ταυτίζονται.

3.12 Εφαρμογή συστάσεων και αναπαραγωγιμότητα

3.12.1 Streamlit app: ποιοτική επιθεώρηση

Το Streamlit dashboard (`app/streamlit_app.py`) είναι ένα *read-only* επίπεδο πάνω από τα τοπικά artifacts που παράγει η offline pipeline (`parquets`, `metrics.json`, graph checkpoints, graph analysis reports). Δεν εκπαιδεύει μοντέλα, δεν επανυπολογίζει embeddings και δεν επιστρέφει σε υπολογισμούς full graph layout. Οι καρτέλες είναι: *Overview*, *Model Comparison*, *Graph Models + Ablations*, *Graph EDA / Communities*, *Item Explorer*, και *Recommendations*.

Η καρτέλα *Recommendations* εκθέτει ντετερμινιστικές συστάσεις ανά χρήστη για έντεκα μεθόδους (popularity, SVD, KNN cosine / pearson / msd, content enriched, calibrated hybrid, LightGCN, GraphSAGE MSE, LLM hybrid profile, LLM hybrid query). Λειτουργεί ως *ποιοτική επιθεώρηση*: δεν αντικαθιστά τις RMSE / MAE / $P@K$ / $R@K$ / $F1@K$ μετρικές που αναφέρονται στην §3. Οι LLM γραμμές εκτελούνται μέσω subprocess (`python -m src.reasoning.explain --full-json`) ώστε να μην μοιραστούν OpenMP runtime με τη Streamlit διαδικασία.

3.12.2 Milvus Lite: semantic retrieval

Τοπικός vector store (`pymilvus.MilvusClient` σε αρχείο `data/storage/milvus_assignment.db`) που αποθηκεύει τα item embeddings (title + description). Χρησιμοποιείται για top- K semantic neighbors είτε από free-text query είτε από user-profile vector (μέσος όρος των high-rated train items του χρήστη). Η εισαγωγή γίνεται με :

```
python -m src.storage.ingest_vectors --dataset <key> --reset.
```

Η ευρετηρίαση δεν αλλάζει τα μετρούμενα αποτελέσματα του recommender: είναι υποδομή ανάκτησης, όχι recommender αντικειμενικό.

3.12.3 Neo4j: train-only γράφος εξηγήσεων

Τοπική Neo4j Community που αποθηκεύει κόμβους `:User`, `:Item`, `:Category` και ακμές `:RATED` μόνο από το train split (`r.split = 'train'`), καθώς και `:IN_CATEGORY` ακμές με το ίδιο φιλτραρισμένο vocabulary κατηγοριών που χρησιμοποιεί το **content_enriched** μοντέλο. Η εισαγωγή γίνεται με `python -m src.storage.ingest_neo4j`. Συμβατό με τον κανόνα διαρροής (§1): τα test ratings δεν εισάγονται.

3.12.4 LLM explanation layer (προαιρετικό)

To `src.reasoning.explain` συνδυάζει τα ήδη εκπαιδευμένα μοντέλα και τα retrieval stores σε ένα ενιαίο pipeline εξήγησης:

1. **Ντετερμινιστική βαθμολόγηση υποψηφίων.** Τέσσερις πηγές score (LightGCN φορτωμένο από checkpoint, SVD εκπαιδευμένο in-CLI, semantic μέσω Milvus, popularity από train counts) min-max κανονικοποιούνται στο $[0, 1]$ ανεξάρτητα, και συνδυάζονται με σταθμισμένο μέσο όρο σε ντετερμινιστικά top- K . Όταν μια πηγή λείπει, τα βάρη ανακατανέμονται στις υπόλοιπες.
2. **Συλλογή τεκμηρίων.** Το Milvus επιστρέφει semantic neighbors· το Neo4j επιστρέφει train-only ιστορικό χρήστη και category overlap. Όλα τυποποιούνται σε αυστηρά Pydantic schemas (RecommendationEvidence / LLMRecommendationResponse).
3. **Επεξήγηση από LLM (Groq, OpenAI-compatible).** Το LLM παίρνει το structured evidence payload και εξηγεί σε φυσική γλώσσα το top- K που έχει ήδη επιλεγεί από την προηγούμενη ντετερμινιστική φάση. Δεν αναδιατάσσει τα αποτελέσματα. Σε --dry-run mode δεν γίνεται κλήση API και επιστρέφεται το payload ως έχει.

Πλαίσιο εκτίμησης. Αυτό το επίπεδο είναι *explanation / retrieval infrastructure*, όχι πρωτεύον αξιολογούμενο recommender. Οι μετρικές της §3 δεν επηρεάζονται από το LLM layer και δεν αναφέρονται LLM-specific RMSE/F1 συγκρίσεις.

3.12.5 Αναπαραγωγικότητα

Πλήρεις εντολές υπάρχουν στο README.md. Η τυπική ροή για το Video_Games:

1. `python -m src.data.fetch --dataset video_games`
2. `python -m src.data.preprocess --dataset video_games`
3. `python -m src.evaluation.evaluate --dataset video_games --no-knn --advanced --tune-alpha`
4. Graph training/eval:
`python -m src.evaluation.evaluate --dataset video_games --graph-only`
5. Επανα-αξιολόγηση checkpoints χωρίς retrain:
`python -m src.evaluation.evaluate_lightgcn_checkpoint ...`
6. App: `streamlit run app/streamlit_app.py`

Όλα τα παραγόμενα δεδομένα (parquets, embeddings, sentiment caches, checkpoints, metrics JSON, Milvus / Neo4j volumes) είναι gitignored: αναπαράγονται τοπικά από τις παραπάνω εντολές και δεν συμπεριλαμβάνονται στο αποθετήριο:
<https://github.com/Fgram-devAI/amazon-hybrid-recsys>.

Κεφάλαιο 4

Συμπεράσματα

4.1 Σύνοψη ευρημάτων

Η εργασία δείχνει ότι στο Video_Games δεν υπάρχει ένα μοναδικό μοντέλο που να υπερέχει σε όλους τους στόχους. Η πρόβλεψη αριθμητικής βαθμολογίας και η παραγωγή μιας καλής top- K λίστας είναι διαφορετικά προβλήματα. Το SVD είναι το ισχυρότερο classic baseline ως προς RMSE, επειδή εκπαιδεύεται απευθείας για rating prediction. Αντίθετα, το LightGCN είναι το ισχυρότερο μοντέλο για sampled ranking, επειδή η BPR αντικειμενική του είναι πιο κοντά στον στόχο της κατάταξης. Αυτό είναι το βασικό συμπέρασμα της πειραματικής μελέτης: η επιλογή μοντέλου πρέπει να εξαρτάται από το αν προτεραιότητα είναι η ακριβής πρόβλεψη rating ή η ποιότητα των πρώτων προτάσεων.

Το content-based σήμα αποδείχθηκε χρήσιμο, αλλά όχι αρκετό από μόνο του. Το plain content-based μοντέλο μένει καθαρά πίσω από το popularity baseline, ενώ το content_enriched μειώνει σημαντικά αυτό το κενό, αξιοποιώντας φιλτραρισμένες κατηγορίες, αριθμητικά metadata και train-only review-feedback. Παρ' όλα αυτά, το καλύτερο content-based αποτέλεσμα δεν αντικαθιστά το collaborative signal. Η συμπεριφορά των χρηστών, όπως εκφράζεται μέσα από τις συν-αξιολογήσεις και τον γράφο user--item, παραμένει το ισχυρότερο σήμα για ranking.

Τα υβριδικά μοντέλα ανέδειξαν ένα πιο λεπτό trade-off. Όταν το βάρος α επιλέγεται με βάση το RMSE, το απλό weighted hybrid δίνει σχεδόν όλο το βάρος στο SVD. Όταν όμως μειώνεται το α , δηλαδή αυξάνεται η συμμετοχή του content-based σήματος, το F1@10 βελτιώνεται εις βάρος του RMSE. Επομένως, το hybridization δεν είναι αυτόματα καλύτερο· χρειάζεται να οριστεί πρώτα ποια μετρική και ποιο επιχειρησιακό ζητούμενο θεωρούνται σημαντικότερα.

4.2 Ερμηνεία των graph αποτελεσμάτων

Τα graph μοντέλα πρόσθεσαν μια πιο σύγχρονη οπτική στο ίδιο πρόβλημα. Το LightGCN, παρότι δεν χρησιμοποιεί metadata, αξιοποιεί πολύ αποτελεσματικά τη δομή του train-only user-item γράφου και γίνεται ο ισχυρότερος ranker. Το GraphSAGE-MSE, αντίθετα, συνδυάζει graph structure και node features και αποδίδει καλύτερα ως rating regressor, αλλά παραμένει ασθενέστερο στο ranking. Η παραλλαγή GraphSAGE-

BPR βελτιώνει την κατάταξη σε σχέση με το GraphSAGE-MSE, αλλά δεν ξεπερνά το LightGCN. Αυτό δείχνει ότι η προσθήκη πολλών features δεν είναι από μόνη της εγγύηση καλύτερης σύστασης: η αντικειμενική συνάρτηση και η καθαρότητα του collaborative signal έχουν μεγάλη σημασία.

Η ανάλυση κοινοτήτων λειτούργησε συμπληρωματικά και όχι ως επιπλέον recommender. Τα item-item co-rating projections και οι αλγόριθμοι Louvain, Leiden, Spectral και Girvan-Newman βοηθούν να εξεταστεί αν η δομή των συν-αξιολογήσεων αντιστοιχεί σε συνεκτικές κατηγορίες προϊόντων. Με αυτόν τον τρόπο, ο γράφος δεν χρησιμοποιείται μόνο για πρόβλεψη, αλλά και για ερμηνεία της εσωτερικής οργάνωσης του dataset.

4.3 Περιορισμοί

Τα αποτελέσματα πρέπει να ερμηνεύονται μέσα στο συγκεκριμένο πειραματικό πρωτόκολλο. Οι ranking μετρικές είναι sampled-candidate και όχι full-catalog, άρα δεν συγκρίνονται άμεσα με εργασίες που κατατάσσουν όλο τον κατάλογο items. Επιπλέον, το Video_Games παραμένει εξαιρετικά αραιό ακόμη και μετά το 5-core filtering. Για αυτό παρουσιάστηκε oracle ceiling: οι χαμηλές τιμές του raw P@10 δεν σημαίνουν απαραίτητα ότι τα μοντέλα είναι άχρηστα, αλλά αντανακλούν και το γεγονός ότι οι περισσότεροι χρήστες έχουν πολύ λίγα relevant held-out items.

Ένας δεύτερος περιορισμός είναι ότι η αξιολόγηση είναι offline. Δεν μετράται πραγματική αλληλεπίδραση χρήστη, diversity, novelty ή long-term engagement. Επίσης, δεν υπάρχουν δημογραφικά χαρακτηριστικά χρηστών, οπότε η προσωποποίηση βασίζεται αποκλειστικά στο ιστορικό αξιολογήσεων και όχι σε ρητό user profile. Τέλος, τα graph experiments έγιναν με τοπικούς υπολογιστικούς πόρους και όχι με εξαντλητικό hyperparameter search.

4.4 Τελική αποτίμηση και μελλοντικές επεκτάσεις

Συνολικά, το σύστημα δείχνει ότι μια υβριδική προσέγγιση είναι χρήσιμη, αλλά η αξία της δεν βρίσκεται απλώς στην πρόσθεση περισσότερων σημάτων. Η πιο καθαρή εικόνα προκύπτει όταν κάθε οικογένεια μοντέλων συνδέεται με τον στόχο που υπηρετεί καλύτερα: SVD για rating prediction, content_enriched για αξιοποίηση metadata και review-feedback, LightGCN για ranking πάνω στον user-item γράφο, και GraphSAGE για μελέτη της σύνδεσης ανάμεσα σε graph structure και node features. Το Streamlit app, το Milvus/Neo4j retrieval layer και το LLM explanation layer λειτουργούν ως επίπεδα επιθεώρησης και εξήγησης πάνω από τα μοντέλα, όχι ως αντικατάσταση της αξιολόγησης.

Μελλοντικά, η μελέτη μπορεί να επεκταθεί με full-catalog evaluation, ranking-aware early stopping για τα graph μοντέλα, ευρύτερο hyperparameter tuning, sequence-aware recommenders όπως SASRec ή BERT4Rec, και πιο εκφραστικές graph-neural μεθόδους όπως SGL, NCL ή UltraGCN. Μια επιπλέον χρήσιμη κατεύθυνση είναι η offline αξιολόγηση των LLM explanations, όχι ως νέου ranker, αλλά ως μηχανισμού που βοηθά τον χρήστη να καταλάβει γιατί προτείνονται συγκεκριμένα items.

Βιβλιογραφία

- [1] Y. Hou, J. Li, Z. He, A. Yan, X. Chen, and J. McAuley. Amazon Reviews 2023: Bridging Language and Items for Retrieval and Recommendation. <https://amazon-reviews-2023.github.io/>, 2024.
- [2] Y. Koren, R. Bell, and C. Volinsky. Matrix factorization techniques for recommender systems. *Computer*, 42(8):30--37, 2009.
- [3] B. Sarwar, G. Karypis, J. Konstan, and J. Riedl. Item-based collaborative filtering recommendation algorithms. In *Proc. WWW*, 2001.
- [4] S. Rendle, C. Freudenthaler, Z. Gantner, and L. Schmidt-Thieme. BPR: Bayesian personalized ranking from implicit feedback. In *Proc. UAI*, 2009.
- [5] X. He, K. Deng, X. Wang, Y. Li, Y.-D. Zhang, and M. Wang. LightGCN: Simplifying and powering graph convolution network for recommendation. In *Proc. SIGIR*, 2020.
- [6] W. L. Hamilton, R. Ying, and J. Leskovec. Inductive representation learning on large graphs. In *NeurIPS*, 2017.
- [7] N. Reimers and I. Gurevych. Sentence-BERT: Sentence embeddings using Siamese BERT-networks. In *EMNLP-IJCNLP*, 2019.
- [8] V. Sanh, L. Debut, J. Chaumond, and T. Wolf. DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter. arXiv:1910.01108, 2019.
- [9] V. D. Blondel, J.-L. Guillaume, R. Lambiotte, and E. Lefebvre. Fast unfolding of communities in large networks. *Journal of Statistical Mechanics: Theory and Experiment*, 2008(10):P10008, 2008.
- [10] M. Girvan and M. E. J. Newman. Community structure in social and biological networks. *Proceedings of the National Academy of Sciences*, 99(12):7821--7826, 2002.
- [11] U. von Luxburg. A tutorial on spectral clustering. *Statistics and Computing*, 17(4):395--416, 2007.
- [12] J. Li, S. Lai, Z. Shuai, *et al.* A comprehensive review of community detection in graphs. 2024.
- [13] A. Kanavos, Y. Voutos, F. Grivokostopoulou, and P. Mylonas. Evaluating methods for efficient community detection in social networks. 2022.

- [14] S. Sobolevsky and A. Belyi. Graph neural network inspired algorithm for unsupervised network community detection. 2022.
- [15] W. L. Hamilton. *Graph Representation Learning*. Morgan & Claypool, 2020.
- [16] D. Easley and J. Kleinberg. *Networks, Crowds, and Markets: Reasoning About a Highly Connected World*. Cambridge University Press, 2010.
- [17] A.-L. Barabási. *Network Science*. Cambridge University Press, 2016.
- [18] J. Leskovec, A. Rajaraman, and J. D. Ullman. *Mining of Massive Datasets*, chapter 10. <http://infolab.stanford.edu/~ullman/mmds/ch10n.pdf>.